

Relatório Técnico: Sistema de Diagnóstico Médico Utilizando Redes Bayesianas

Donvicton Monteiro, Yuck Arthur, Efraim Leite,
Jadiel Henrique, John Wallex, Neilton Gabriel

26 de junho de 2026

Disciplina: Inteligência Artificial
Representação do Conhecimento sob Incerteza

Sumário

1	Descrição do Domínio	2
1.1	Doenças Modeladas	2
1.2	Justificativa da Escolha	2
2	Modelagem da Rede Bayesiana	2
2.1	Variáveis do Modelo	2
2.2	Estrutura do Grafo (DAG)	3
2.3	Justificativa das Relações de Dependência	3
2.4	Independências Condicionais	4
3	Tabelas de Probabilidades Condicionais (CPTs)	4
3.1	Nós Raiz — Fatores de Risco	5
3.2	Doenças — Condicionadas aos Fatores de Risco	5
3.3	Sintomas — Condicionados às Doenças	6
4	Exemplos de Inferência	7
4.1	Experimento 1: Diagnóstico a partir de sintomas iniciais	7
4.2	Experimento 2: Atualização do diagnóstico com novas evidências	7
4.3	Experimento 3: Comparação entre perfis de pacientes	8
5	Análise e Discussão dos Resultados	8
5.1	Representação da Incerteza	8
5.2	Influência das Evidências no Diagnóstico	9
5.3	Vantagens sobre Sistemas Baseados em Regras	9
5.4	Limitações do Modelo	10
5.5	Possíveis Melhorias	10
6	Implementação Técnica	10

1 Descrição do Domínio

O domínio escolhido para este sistema é o **diagnóstico de doenças respiratórias**, um dos campos mais relevantes da medicina clínica, especialmente após a pandemia de COVID-19. Doenças respiratórias representam uma das principais causas de atendimento em unidades de saúde no Brasil e no mundo, e frequentemente compartilham sintomas similares, tornando o diagnóstico diferencial um desafio clínico significativo.

1.1 Doenças Modeladas

O sistema abrange três doenças respiratórias de alta prevalência:

- **Gripe (Influenza):** Infecção viral aguda do trato respiratório, causada pelo vírus *Influenza*. Caracteriza-se por febre alta de início súbito, dores musculares intensas e tosse seca. Prevalência sazonal estimada em 10–20% da população.
- **Pneumonia:** Infecção que acomete os pulmões, podendo ser causada por bactérias, vírus ou fungos. Apresenta como sintomas marcantes a dispnéia (falta de ar), febre persistente e tosse produtiva. Tabagismo e idade avançada são fatores de risco bem estabelecidos na literatura.
- **COVID-19:** Doença causada pelo coronavírus SARS-CoV-2. Além de sintomas respiratórios clássicos, apresenta como sintoma altamente específico a perda de olfato (anosmia), o que a diferencia das demais doenças modeladas.

1.2 Justificativa da Escolha

A escolha deste domínio justifica-se por:

1. As três doenças possuem **sintomas sobrepostos** (febre, tosse), tornando a inferência probabilística especialmente útil para diferenciá-las;
2. Existem **fatores de risco** bem documentados (idade, tabagismo) que influenciam a suscetibilidade de forma quantificável;
3. A relevância clínica e epidemiológica do tema é alta, com dados amplamente disponíveis para embasar as probabilidades;
4. O cenário ilustra claramente como a **incerteza diagnóstica** pode ser tratada de forma formal e matemática.

2 Modelagem da Rede Bayesiana

2.1 Variáveis do Modelo

A rede contém **10 variáveis binárias** (Sim/Não), organizadas em três camadas semânticas:

Tabela 1: Variáveis do modelo e seus significados

Camada	Variável	Descrição
Fatores de Risco	Idoso	Paciente com idade ≥ 60 anos. A imunossenescência aumenta a suscetibilidade a infecções respiratórias.
	Fumante	Paciente tabagista ativo. O tabagismo compromete a função pulmonar e é fator de risco especialmente para pneumonia.
Doenças	Gripe	Presença de infecção pelo vírus <i>Influenza</i> .
	Pneumonia	Presença de infecção pulmonar (bacteriana ou viral).
	COVID-19	Presença de infecção pelo SARS-CoV-2.
Sintomas	Febre	Temperatura corporal elevada ($> 37,8^{\circ}\text{C}$).
	Tosse	Tosse seca ou produtiva persistente.
	Dor Muscular	Mialgia generalizada e dores no corpo.
	Dispneia	Dificuldade respiratória ou falta de ar.
	Perda Olfato	Anosmia — perda parcial ou total do olfato.

2.2 Estrutura do Grafo (DAG)

A Rede Bayesiana é representada por um **Grafo Direcionado Acíclico (DAG)** com 10 nós e 15 arestas. As arestas representam relações causais diretas: fatores de risco influenciam a probabilidade das doenças, e as doenças causam os sintomas observáveis.




Figura 1: Estrutura da Rede Bayesiana — Diagnóstico de Doenças Respiratórias.

● Fatores de Risco ● Doenças ● Sintomas

2.3 Justificativa das Relações de Dependência

Cada aresta do grafo é justificada por relações causais conhecidas:

- **Idoso $\rightarrow$ Gripe, Pneumonia, COVID-19:** A idade avançada é um fator de risco

transversal a todas as doenças respiratórias devido à imunossenescência (declínio natural do sistema imunológico com o envelhecimento).

- **Fumante $\rightarrow$ Pneumonia:** O tabagismo compromete os mecanismos de defesa pulmonar (clearance mucociliar), aumentando significativamente o risco de pneumonia. Não há aresta Fumante $\rightarrow$ Gripe porque o tabagismo não altera substancialmente a suscetibilidade à infecção pelo *Influenza*.
- **Gripe $\rightarrow$ Febre, Tosse, DorMuscular:** São os sintomas clássicos da síndrome gripal, com alta sensibilidade na literatura clínica.
- **Pneumonia $\rightarrow$ Febre, Tosse, Dispneia:** Dispneia é um marcador importante de comprometimento pulmonar, diferenciando pneumonia da gripe comum.
- **COVID-19 $\rightarrow$ Febre, Tosse, DorMuscular, Dispneia, PerdaOlfato:** A COVID-19 causa o espectro mais amplo de sintomas entre as três doenças. A perda de olfato é exclusivamente associada a COVID-19 neste modelo, refletindo sua alta especificidade clínica documentada.

2.4 Independências Condicionais

A estrutura do DAG implica diversas independências condicionais relevantes, derivadas automaticamente pelo critério *d-separação*:

- Gripe $\perp$ Fumante — Fumar não influencia a probabilidade de gripe;
- Gripe $\perp$ Pneumonia | Idoso — As doenças são independentes dado o fator de risco;
- PerdaOlfato $\perp$ Pneumonia | COVID-19 — A perda de olfato depende apenas da COVID-19;
- DorMuscular $\perp$ Pneumonia | Gripe, COVID-19 — Dor muscular não é causada por pneumonia;
- Idoso $\perp$ Fumante — Os fatores de risco são independentes entre si;
- COVID-19 $\perp$ Fumante — O tabagismo não influencia diretamente a infecção por SARS-CoV-2 neste modelo.

3 Tabelas de Probabilidades Condicionais (CPTs)

As probabilidades foram definidas com base em dados epidemiológicos plausíveis para fins educacionais, considerando prevalências sazonais típicas do Brasil (OMS, Ministério da Saúde, IBGE) e sensibilidade aproximada de sintomas reportada na literatura clínica.

3.1 Nós Raiz — Fatores de Risco

Tabela 2: Probabilidades a priori dos fatores de risco

Variável	P(Sim)	P(Não)	Fonte/Justificativa
Idoso (≥ 60 anos)	0,15	0,85	IBGE — proporção da população ≥ 60 anos
Fumante	0,12	0,88	PNS/IBGE — prevalência de tabagismo adulto

3.2 Doenças — Condiionadas aos Fatores de Risco

Tabela 3: $P(\text{Gripe} \mid \text{Idoso})$

	Idoso = Não	Idoso = Sim
$P(\text{Gripe} = \text{Sim})$	0,10	0,20
$P(\text{Gripe} = \text{Não})$	0,90	0,80

Justificativa: Idosos apresentam o dobro da taxa de incidência de gripe sintomática em relação a adultos jovens, devido ao declínio imunológico associado ao envelhecimento.

Tabela 4: $P(\text{Pneumonia} \mid \text{Idoso}, \text{Fumante})$

	Idoso = Não		Idoso = Sim	
	Fum.=Não	Fum.=Sim	Fum.=Não	Fum.=Sim
$P(\text{Pneumonia} = \text{Sim})$	0,03	0,08	0,12	0,25
$P(\text{Pneumonia} = \text{Não})$	0,97	0,92	0,88	0,75

Justificativa: A pneumonia é fortemente influenciada por ambos os fatores de risco. Um idoso fumante tem probabilidade de 25%, mais de 8 vezes a taxa base de 3% para um adulto jovem não fumante. Isso reflete a sinergia entre a imunossenescência e o comprometimento pulmonar pelo tabagismo.

Tabela 5: $P(\text{COVID-19} \mid \text{Idoso})$

	Idoso = Não	Idoso = Sim
$P(\text{COVID-19} = \text{Sim})$	0,05	0,12
$P(\text{COVID-19} = \text{Não})$	0,95	0,88

Justificativa: Idosos apresentam maior taxa de casos sintomáticos e diagnósticos confirmados de COVID-19, embora a taxa de infecção não difira tanto quanto a de gravidade.

3.3 Sintomas — Condicionados às Doenças

Tabela 6: $P(\text{Febre} \mid \text{Gripe, Pneumonia, COVID-19})$ — valores para $P(\text{Febre} = \text{Sim})$

	Gripe = Não				Gripe = Sim			
	Pn.=Não		Pn.=Sim		Pn.=Não		Pn.=Sim	
	C=N	C=S	C=N	C=S	C=N	C=S	C=N	C=S
$P(\text{Febre}=\text{S})$	0,05	0,88	0,85	0,95	0,90	0,95	0,95	0,98

Justificativa: Febre é comum nas três doenças (alta sensibilidade), mas rara sem nenhuma delas (5%). Quando múltiplas doenças estão presentes simultaneamente, a probabilidade de febre se aproxima de 98%.

Tabela 7: $P(\text{Perda de Olfato} \mid \text{COVID-19})$

	COVID-19 = Não	COVID-19 = Sim
$P(\text{PerdaOlfato} = \text{Sim})$	0,02	0,70
$P(\text{PerdaOlfato} = \text{Não})$	0,98	0,30

Justificativa: A perda de olfato é o sintoma mais discriminante do modelo. Cerca de 70% dos pacientes com COVID-19 a apresentam, contra apenas 2% na população sem a doença. Essa alta especificidade faz com que este sintoma seja o maior diferenciador na inferência.

Tabela 8: $P(\text{Dor Muscular} \mid \text{Gripe, COVID-19})$ — valores para $P(\text{DorMuscular} = \text{Sim})$

	Gripe = Não		Gripe = Sim	
	COVID=Não	COVID=Sim	COVID=Não	COVID=Sim
$P(\text{DorMuscular} = \text{Sim})$	0,08	0,75	0,80	0,90

Tabela 9: $P(\text{Dispneia} \mid \text{Pneumonia, COVID-19})$ — valores para $P(\text{Dispneia} = \text{Sim})$

	Pneumonia = Não		Pneumonia = Sim	
	COVID=Não	COVID=Sim	COVID=Não	COVID=Sim
$P(\text{Dispneia} = \text{Sim})$	0,04	0,60	0,70	0,85

Justificativa: A dispneia é um marcador de gravidade e comprometimento pulmonar, associada principalmente a pneumonia e COVID-19. Raramente ocorre isoladamente sem doença respiratória (4%).

4 Exemplos de Inferência

A inferência foi realizada utilizando o algoritmo de **Eliminação de Variáveis**, implementado na biblioteca `pgmpy` para Python. As probabilidades a priori (sem qualquer evidência) são:

Tabela 10: Probabilidades a priori das doenças

Doença	P(Doença = Sim)
Gripe	11,50%
Pneumonia	5,09%
COVID-19	6,05%

4.1 Experimento 1: Diagnóstico a partir de sintomas iniciais

Cenário: Paciente apresenta febre e tosse, sem outras informações.

Evidências: Febre = Sim, Tosse = Sim.

Tabela 11: Resultado da inferência — Experimento 1

Doença	P a priori	P a posteriori	Variação
Gripe	11,50%	53,16%	+41,66 p.p.
Pneumonia	5,09%	25,42%	+20,33 p.p.
COVID-19	6,05%	29,36%	+23,31 p.p.

Interpretação: Febre e tosse são sintomas compartilhados pelas três doenças, o que explica o aumento das probabilidades de todas elas. A gripe lidera com 53,16% porque apresenta as maiores taxas de sensibilidade conjunta para esses dois sintomas. Contudo, a incerteza permanece significativa — nenhuma doença ultrapassa o limiar de certeza diagnóstica.

4.2 Experimento 2: Atualização do diagnóstico com novas evidências

Cenário: Atualização incremental das evidências para demonstrar como a rede refina o diagnóstico a cada nova informação.

Tabela 12: Atualização progressiva das probabilidades

Doença	A priori	+ Febre	+ Dor Muscular	+ Perda Olfato
Gripe	11,50%	46,37%	67,32%	20,30%
Pneumonia	5,09%	19,73%	8,50%	7,17%
COVID-19	6,05%	24,04%	33,33%	94,59%

Interpretação da propagação:

1. **Etapa A — Febre:** Sintoma inespecífico que eleva todas as doenças proporcionalmente. A gripe lidera (46,37%) por ter a maior prevalência a priori combinada com alta sensibilidade de febre.
2. **Etapa B — Febre + Dor Muscular:** A dor muscular não é causada por pneumonia neste modelo (independência condicional), fazendo sua probabilidade *cair* de 19,73% para 8,50%. Gripe e COVID-19, ambas causadoras de mialgia, sobem significativamente.
3. **Etapa C — Febre + Dor Muscular + Perda de Olfato:** A perda de olfato é o divisor diagnóstico. Com especificidade de 70% para COVID-19 e apenas 2% de base, este sintoma faz a probabilidade de COVID-19 saltar de 33,33% para **94,59%**. Simultaneamente, a gripe despenca de 67,32% para 20,30%, demonstrando o poder discriminante de sintomas específicos.

4.3 Experimento 3: Comparação entre perfis de pacientes

Cenário: Três perfis distintos com os mesmos sintomas respiratórios (dispneia + tosse) mas diferentes fatores de risco, além de um perfil contrastante.

Tabela 13: Comparação entre perfis de pacientes

Doença	A priori	Perfil A	Perfil B	Perfil C
		Jovem + Disp.	Idoso Fum. + Disp.	Febre + Dor, sem Disp.
Gripe	11,50%	14,98%	22,67%	81,02%
Pneumonia	5,09%	42,67%	75,69%	3,02%
COVID-19	6,05%	48,33%	32,83%	17,53%

Interpretação:

- **Perfil A** (Jovem, dispneia + tosse): A dispneia aponta para COVID-19 (48,33%) e pneumonia (42,67%), com incerteza significativa entre ambas.
- **Perfil B** (Idoso fumante, dispneia + tosse): Os fatores de risco amplificam a probabilidade de pneumonia para **75,69%**. A combinação de idade avançada e tabagismo aumenta a probabilidade a priori de pneumonia de 3% para 25% (conforme a CPT), o que se propaga para o resultado final.
- **Perfil C** (Febre + dor muscular, *sem* dispneia): A *ausência* de dispneia é evidência negativa que reduz pneumonia (3,02%) e COVID-19 (17,53%), favorecendo fortemente a gripe (**81,02%**).

5 Análise e Discussão dos Resultados

5.1 Representação da Incerteza

A Rede Bayesiana representa a incerteza diagnóstica por meio de **distribuições de probabilidade condicional**. Cada nó possui uma CPT que quantifica numericamente a relação entre variáveis. Diferentemente de sistemas determinísticos que classificam em

“doente” ou “saúdável”, o modelo produz um *espectro de probabilidades* que reflete a realidade clínica: um paciente com febre e tosse *pode* ter gripe, pneumonia ou COVID-19, e o sistema quantifica exatamente o grau de crença em cada hipótese.

A propagação de evidências pela rede atualiza *todas* as probabilidades simultaneamente via Teorema de Bayes:

$$P(D | E) = \frac{P(E | D) \cdot P(D)}{P(E)} \quad (1)$$

onde $P(D | E)$ é a probabilidade a posteriori da doença D dadas as evidências E , $P(E | D)$ é a verossimilhança extraída da CPT, $P(D)$ é a probabilidade a priori, e $P(E)$ é a probabilidade marginal das evidências.

5.2 Influência das Evidências no Diagnóstico

Os experimentos revelaram padrões claros sobre a influência de cada tipo de evidência:

- **Sintomas inespecíficos** (febre, tosse): Elevam as probabilidades de *todas* as doenças proporcionalmente às suas verossimilhanças. São insuficientes para um diagnóstico diferencial, mas reduzem a incerteza global — saber que o paciente tem febre já exclui parcialmente a hipótese “nenhuma doença”.
- **Sintomas específicos** (perda de olfato, dispneia): São discriminantes poderosos. A perda de olfato, com razão de verossimilhança $\frac{P(PO=S|COVID=S)}{P(PO=S|COVID=N)} = \frac{0,70}{0,02} = 35$, desloca massivamente a probabilidade em favor de COVID-19.
- **Fatores de risco**: Modulam as probabilidades a priori. Um idoso fumante já inicia a consulta com 25% de probabilidade de pneumonia (vs. 3% para jovem não fumante), alterando todo o diagnóstico subsequente.
- **Evidências negativas**: Tão informativas quanto as positivas. A *ausência* de dispneia no Perfil C do Experimento 3 reduziu a pneumonia de 5,09% para 3,02%.

5.3 Vantagens sobre Sistemas Baseados em Regras

Tabela 14: Comparação: Redes Bayesianas vs. Sistemas de Regras

Aspecto	Rede Bayesiana	Sistema de Regras
Tratamento de incerteza	Probabilidades contínuas $[0, 1]$	Binário (Sim/Não)
Atualização incremental	Cada evidência refina o resultado	Regras são avaliadas de forma estática
Inferência bidirecional	Pode ir de sintomas a doenças e vice-versa	Unidirecional (SE... ENTÃO)
Evidências incompletas	Funciona com qualquer subconjunto	Pode falhar se faltar condição
Transparência	CPTs explícitas e auditáveis	Regras podem ser opacas em grande escala
Base matemática	Teorema de Bayes, teoria da probabilidade	Lógica proposicional

5.4 Limitações do Modelo

1. **CPTs estimadas:** As probabilidades foram definidas com base em estimativas plausíveis para fins educacionais, não calibradas com dados clínicos reais. Em um sistema de produção, as CPTs deveriam ser aprendidas a partir de bases de dados médicas.
2. **Variáveis binárias:** O modelo simplifica variáveis contínuas (temperatura, saturação de O_2) em categorias binárias, perdendo informação sobre a gravidade dos sintomas.
3. **Conjunto limitado:** Apenas 3 doenças e 5 sintomas não capturam a complexidade real do diagnóstico respiratório. Tuberculose, asma, bronquite e alergias ficaram fora do escopo.
4. **Sem comorbidades:** O modelo não considera que um paciente pode ter gripe e pneumonia simultaneamente, embora a rede permita essa inferência em termos probabilísticos.
5. **Sem temporalidade:** Não incorpora a duração dos sintomas, que é um fator diagnóstico importante na prática clínica.

5.5 Possíveis Melhorias

- Calibrar as CPTs com dados reais de prontuários médicos (aprendizado de parâmetros);
- Adicionar variáveis contínuas (temperatura, saturação O_2) usando nós gaussianos ou discretização;
- Incluir mais doenças (tuberculose, asma, bronquite) e exames complementares (raio-X, PCR, hemograma);
- Incorporar variáveis temporais (duração dos sintomas, estação do ano);
- Implementar aprendizado de estrutura a partir de dados, descobrindo relações causais automaticamente;
- Desenvolver uma interface gráfica clínica para uso real em triagem hospitalar.

6 Implementação Técnica

O sistema foi implementado em **Python 3.13** utilizando as seguintes bibliotecas:

- **pgmpy** — Modelagem e inferência em Redes Bayesianas (classe `DiscreteBayesianNetwork`, inferência por `VariableElimination`);
- **Flask** — Framework web para a interface interativa;
- **matplotlib + networkx** — Visualização gráfica da rede;
- **tabulate** — Formatação dos resultados no terminal.

A interface web permite ao usuário selecionar interativamente os fatores de risco e sintomas, visualizando em tempo real a propagação da inferência bayesiana etapa por etapa, as probabilidades a priori e a posteriori, e a estrutura completa da rede com suas CPTs e explicação teórica.

O código-fonte está disponível nos arquivos `app.py` (servidor web + modelo) e `diagnostico_bayesia` (versão terminal).

Referências

- [1] RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. 4. ed. Hoboken: Pearson, 2021. Capítulos 12–14: Quantifying Uncertainty, Probabilistic Reasoning, Probabilistic Reasoning over Time.
- [2] KOLLER, D.; FRIEDMAN, N. **Probabilistic Graphical Models: Principles and Techniques**. Cambridge: MIT Press, 2009.
- [3] PEARL, J. **Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference**. San Francisco: Morgan Kaufmann, 1988.
- [4] ORGANIZAÇÃO MUNDIAL DA SAÚDE (OMS). *Influenza (Seasonal) — Fact Sheet*. Disponível em: [https://www.who.int/news-room/fact-sheets/detail/influenza-\(seasonal\)](https://www.who.int/news-room/fact-sheets/detail/influenza-(seasonal)). Acesso em: 20 jun. 2026.
- [5] ORGANIZAÇÃO MUNDIAL DA SAÚDE (OMS). *Coronavirus disease (COVID-19) — Overview*. Disponível em: <https://www.who.int/health-topics/coronavirus>. Acesso em: 20 jun. 2026.
- [6] INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). *Pesquisa Nacional por Amostra de Domicílios Contínua — Características gerais dos moradores 2022*. Rio de Janeiro: IBGE, 2023. Dados utilizados: proporção da população com 60 anos ou mais ($\approx 15\%$).
- [7] INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). *Pesquisa Nacional de Saúde (PNS) 2019: Informações sobre domicílios, acesso e utilização dos serviços de saúde*. Rio de Janeiro: IBGE, 2020. Dados utilizados: prevalência de tabagismo na população adulta ($\approx 12,6\%$).
- [8] LECHIEN, J. R. et al. Olfactory and gustatory dysfunctions as a clinical presentation of mild-to-moderate forms of the coronavirus disease (COVID-19). **European Archives of Oto-Rhino-Laryngology**, v. 277, n. 8, p. 2251–2261, 2020. DOI: <https://doi.org/10.1007/s00405-020-05965-1>. Dados utilizados: prevalência de anosmia em pacientes COVID-19 ($\approx 70\text{--}86\%$).
- [9] TORRES, A. et al. Pneumonia. **Nature Reviews Disease Primers**, v. 7, n. 1, p. 25, 2021. DOI: <https://doi.org/10.1038/s41572-021-00259-0>. Dados utilizados: fatores de risco (idade, tabagismo) e sintomas associados à pneumonia.
- [10] BRASIL. Ministério da Saúde. *Guia de Vigilância em Saúde*. 5. ed. Brasília: Ministério da Saúde, 2022. Dados utilizados: perfil sintomático de síndrome gripal e síndrome respiratória aguda grave (SRAG).
- [11] ANKAN, A.; PANDA, A. pgmpy: Probabilistic Graphical Models using Python. In: **Proceedings of the 14th Python in Science Conference (SciPy)**, 2015, p. 6–11. Disponível em: <https://pgmpy.org>. Acesso em: 20 jun. 2026.
- [12] PALLETS PROJECTS. *Flask: Web development, one drop at a time*. Disponível em: <https://flask.palletsprojects.com>. Acesso em: 20 jun. 2026.